Classificazione della Qualità del Vino Rosso

Monica Bagnasco Danilo Buttu Beatrice Gnai
Francesco Licitra Raffaele Vita

***Abstract*—La classificazione automatica della qualità del vino rosso da parametri fisico-chimici deve affrontare sbilanciamento delle classi, rumore sintetico e non linearità. Si confrontano kNN, regressione logistica e Random Forest, valutando l'impatto di rumore e PCA. Solo Random Forest trae vantaggio dall'oversampling sulle classi minoritarie, superando nettamente gli altri modelli in capacità predittiva, con buone prospettive per il controllo qualità enologico.**

I. Introduzione

Nella moderna industria vitivinicola, la tradizionale valutazione della qualità affidata all'analisi sensoriale dei sommelier comporta costi elevati e una variabilità intrinseca dovuta alla soggettività umana. L'implementazione di sistemi di classificazione automatica basati sulla composizione fisico-chimica oggettiva permette invece di standardizzare i controlli, ottimizzare le strategie di pricing e supportare le decisioni in cantina con interventi correttivi tempestivi.
L'obiettivo di questa ricerca è sviluppare un sistema predittivo per la qualità del vino rosso. La variabile target, *Wine Quality*, definisce il punteggio assegnato dagli esperti su una scala da 3 (qualità molto scarsa) a 8 (qualità eccellente).
Il report illustra nel dettaglio l'architettura dei modelli applicati e le relative scelte metodologiche adottate per la gestione dei dati e del rumore.

II. Analisi dei dati

Il dataset descrive il profilo enologico di campioni di vino rosso attraverso parametri continui quali acidità, zuccheri residui, cloruri, anidride solforosa (libera e totale), densità, pH, solfati e alcol. Include inoltre le variabili di controllo *Synthetic_Noise_Flag* (presenza di rumore nei dati) e *Volatile_Enhanced* (indicatore di elevata acidità volatile).
La variabile target, *WineQuality*, esprime dei punteggi ordinali compresi tra 3 (qualità molto scarsa) e 8 (qualità eccellente). L'analisi esplorativa evidenzia un profondo sbilanciamento nella distribuzione delle classi, che possiamo interpretare nel seguente modo: in contesti reali di controllo qualità, in cui la maggior parte della produzione si concentra su livelli medi, i vini eccezionali o marcatamente difettosi rappresentano eccezioni statistiche. Date le differenti scale di grandezza delle feature, i dati sono stati sottoposti a standardizzazione. In assenza di tale trasformazione, variabili con ordini di grandezza elevati (come *total_sulfur_dioxide*) avrebbero dominato rispetto a variabili con scale inferiori (quali *chlorides* e *citric_acid*).
I valori mancanti sono stati invece gestiti tramite l'imputazione della mediana, scelta ottimale per garantire robustezza contro outlier o in presenza di distribuzioni asimmetriche. L'analisi della correlazione di Pearson (Figura 2) ha permesso di individuare la presenza di relazioni lineari tra le variabili e il target, in particolare, *alcohol*, *citric_acid* e *sulphates* mostrano un impatto positivo sulla qualità, mentre *volatile_acidity* presenta una forte correlazione negativa, riscontro chimicamente coerente poiché quest'ultima riflette l'ossidazione acetica del vino. L'analisi evidenzia inoltre fenomeni di multicollinearità tra specifiche coppie di variabili: *alcohol* e *Alcohol_Density_Ratio*, *volatile_acidity* e *Volatile_Enhanced*, e infine *sulphates* e *Acidity_Sulfur_Interaction*.

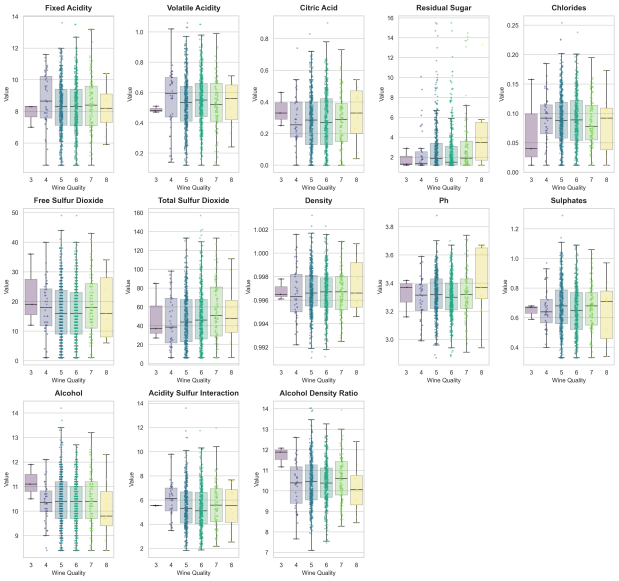


Fig. 1. Distribuzione delle caratteristiche chimiche in relazione alla qualità del vino.

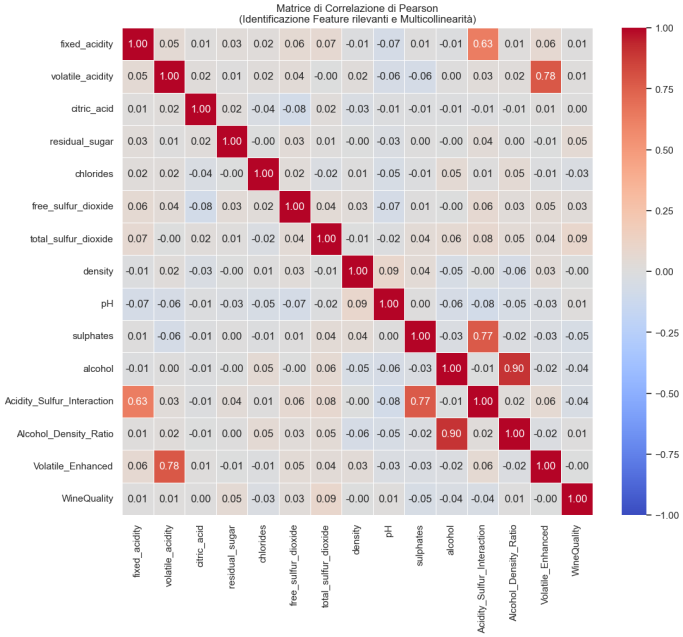


Fig. 2. Matrice di correlazione di Pearson.

Infine, la variabile *Synthetic_Noise_Flag* è stata utilizzata per strutturare lo studio secondo due scenari comparativi paralleli. Il modello infatti è stato valutato su due versioni distinte del training set: una "rumorosa", comprensiva delle osservazioni alterate artificialmente (*Synthetic_Noise_Flag=1*), e una "pulita", limitata ai soli campioni originari (*Synthetic_Noise_Flag=0*).

III. Metodologia

Il primo passo effettuato nella ricerca è un'accurata esplorazione dei dati, durante la quale è stata verificata l'integrità di questi, nell'eventuale presenza di valori mancanti o outlier. Successivamente sono stati implementati algoritmi di apprendimento supervisionato quali:

- K-Nearest Neighbors (kNN), implementato per valutare la classificazione in base alla vicinanza topologica dei dati nello spazio delle feauture;
- Regressione Logistica (RL), per la sua capacità di modellare le probabilità di appartenenza a ciascuna classe di qualità attraverso una funzione logistica estesa al caso multiclasse;
- Random Forest (RF), per la sua intrinseca robustezza rispetto alla variabilità e al rumore del dataset.

Per ottimizzare le prestazioni e gestire la complessità dello spazio dei parametri, è stata inoltre applicata la Principal Component Analysis (PCA), valutando l'impatto della riduzione dimensionale sulla capacità predittiva dei modelli.
A differenza di un approccio metodologico rigido, che imporrebbe la medesima *pipeline* di partizionamento per ogni modello, in questo studio si è optato per una strategia adattiva orientata all'algoritmo. Infatti, la grave scarsità di campioni per le classi minoritarie (ad esempio, le sole 3 istanze per la classe di qualità 3) ha reso impossibile l'adozione di un unico framework di validazione universale. Questo è evidente specialmente nella scelta di differenziare i meccanismi di ricampionamento. L'oversampling non garantisce automaticamente un miglioramento delle performance per tutti gli algoritmi. Infatti RF ne beneficia maggiormente poichè è un modello robusto e meno sensibile al rumore introdotto dai dati sintetici, modelli come LR e kNN ne risentono negativamente perchè introduce punti poco rappresentativi.
Sulla base dei risultati emersi dalla matrice di correlazione, è stata effettuata una distinzione strategica tra feature primarie e feature secondarie (quelle ottenute tramite trasformazione delle primarie). In ciascun algotimo implementato, si è scelto di semplificare lo spazio delle feature mantendendo solo quelle primarie e preferendo sempre quelle a dominio continuo visto gli algoritmi utilizzati.
Per l'inferenza finale, è stato utilizzato un *Test Set* mantenuto rigorosamente isolato durante tutte le fasi di pre-elaborazione e scelta dei parametri, al fine di garantire una valutazione della capacità di generalizzazione del modello su dati non osservati in fase di addestramento. Di seguito si presentano nel dettaglio le scelte metodologiche effettuate per ciascun algortimo.

A. *K-Nearest Neighbors (kNN)*

L'algoritmo kNN è un classificatore superviosanto non parametrico basato sulla prossimità geometrica nello spazio delle feature. Essendo un modello di "apprendimento pigro", (*memory-based*), si limita a memorizzare l'intero set di dati di addestramento senza estrarre regole a priori, rimandando l'elaborazione alla fase di inferenza. La classificazione di una nuova istanza avviene confrontandola con i k campioni più vicini tramite la distanza Euclidea e assegnando la classe prevalente per voto di maggioranza con una politica di *majority voting*.
La pipeline include una sequenza di trasformazioni preliminari volte a migliorarne la qualità dei dati: l'imputazione dei valori mancanti con la mediana, la standardizzazione delle variabili e una fase di *feature selection* tramite l'algoritmo `SelectKBest` (con scoring `mutual_info_classif`) per isolare le feature più informative rispetto al target. A causa della sua natura *memory-based*, si è scelto di non dividere ulteriormente il *training set* estraendo un *validation set* statico . Sottrarre campioni avrebbe reso lo spazio multidimensionale eccessivamente sparso, isolando le classi minoritarie e favorendo l'erronea assegnazione sistematica delle etichette predominanti (classi 5 e 6).
La *Cross-Validation* è stata confinata esclusivamente alla fase di *tuning* dell'iperparametro k. La scelta del parametro ottimale k è stata effettuata tramite l'*Elbow Method* (Figura 3), analizzando l'andamento delle prestazioni del modello al variare del numero di vicini considerati. Come metrica di valutazione è stato utilizzato l'F1-Score macro invece della semplice accuratezza per contrastare il forte sbilanciamento del dataset.

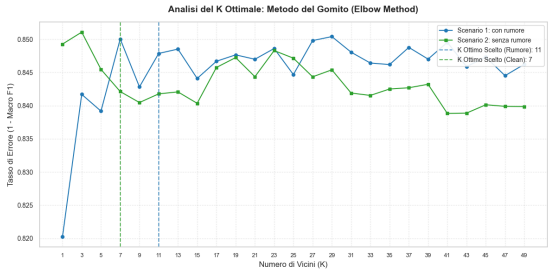


Fig. 3. Determinazione dell'iperparametro k tramite Elbow Method.

I valori ottimali selezionati sono $k = 11$ per lo scenario con rumore e $k = 7$ per quello pulito. Il modello è stato infine riaddestrato sull'intero set di training per garantire la massima densità topologica possibile nella fase di test finale.

B. *Regressione Logistica (RL)*

Il metodo RL stima la probabilità che un campione appartenga a una determinata classe sulla base di una combinazione lineare delle variabili di input. Nel presente lavoro, essendo il problema multiclasse, il modello viene esteso al caso in cui siano presenti più classi di qualità. Per ogni vino, il classificatore calcola quindi una probabilità associata a ciascuna classe possibile e assegna l'etichetta corrispondente alla probabilità più elevata.
L'obiettivo del modello è apprendere dei coefficienti associati alle diverse feature chimiche, in modo da descrivere quanto ciascuna variabile contribuisca alla separazione tra le classi. In questo senso, la Regressione Logistica rappresenta un modello lineare e probabilistico: lineare perché costruisce la decisione a partire da una combinazione pesata delle feature, probabilistico perché restituisce una stima della probabilità di appartenenza alle classi.
Prima dell'addestramento, le feature sono state normalizzate mediante `MinMaxScaler`. Questa trasformazione riporta ciascuna variabile numerica in un intervallo comune compreso tra 0 e 1. La normalizzazione è particolarmente importante per la Regressione Logistica, poiché il modello stima i coefficienti attraverso un processo di ottimizzazione numerica che può essere influenzato dalla diversa scala delle variabili. Senza questa fase, feature con valori numericamente più elevati potrebbero avere un impatto eccessivo rispetto a variabili espresse su scale più piccole, rendendo il processo di apprendimento meno stabile.
Per valutare il comportamento del modello durante la fase di addestramento è stata utilizzata una `StratifiedKFold Cross-Validation` a 3 fold, con mescolamento casuale dei dati e `random_state` fissato per garantire la riproducibilità dell'esperimento. La scelta della versione stratificata della cross-validation è motivata dallo sbilanciamento della variabile target: alcune classi di qualità sono molto meno frequenti rispetto alle classi centrali. La stratificazione consente quindi di mantenere, per quanto possibile, una distribuzione simile delle

classi all'interno di ciascun fold.

C. *Random Forest (RF)*

L'algoritmo Random Forest (RF) è un metodo di apprendimento supervisionato appartenente alla categoria degli ensemble methods, basato sulla combinazione di molteplici alberi decisionali indipendenti costruiti su sottoinsiemi casuali del dataset. Le predizioni dei singoli alberi vengono aggregate tramite majority voting, consentendo di ridurre la varianza del modello e migliorare la capacità di generalizzazione rispetto a un singolo decision tree.

Random Forest è stato scelto per la sua robustezza rispetto al rumore e alla presenza di relazioni non lineari tra le variabili chimico-fisiche del vino. Inoltre, il modello risulta meno sensibile alla diversa scala numerica delle feature rispetto ad algoritmi distance-based come kNN.

Prima dell'addestramento, i valori mancanti presenti nel dataset sono stati gestiti mediante imputazione tramite la mediana delle rispettive feature numeriche. Successivamente, a causa del forte sbilanciamento della variabile target WineQuality, è stata applicata una procedura di oversampling delle classi minoritarie tramite resampling con reinserimento, con l'obiettivo di ridurre il bias del classificatore verso le classi dominanti e migliorare la capacità discriminativa del modello nei confronti delle etichette meno rappresentate.

A differenza di algoritmi fortemente dipendenti dalla struttura geometrica locale del dataset (come kNN), Random Forest beneficia maggiormente delle tecniche di oversampling, ridultando meno sensibile alla presenza di campiomi sintetici duplicati.

Gli iperparametri del modello sono stati ottimizzati mediante Grid Search combinata con Stratified Cross Validation a 3 fold. Analogamente agli altri modelli implementati, come metrica di riferimento è stato utilizzando l'F1-score macro, ritenuto maggiormente rappresentativo in presenza di dataset fortemente sbilanciati.

D. *Principal Component Analalysis (PCA)*

Il metodo PCA è stato utilizzato con l'obiettivo di ridurre la dimensionalità del dataset, trasformando le variabili chimiche del vino in un nuovo insieme di variabili non correlate, chiamate componenti principali. In questo modo è possibile mantenere la maggior parte dell'informazione contenuta nei dati originali, riducendo allo stesso tempo la complessità del problema.

Prima dell'applicazione della PCA, per ogni colonna numerica, gli eventuali valori nulli sono stati sostituiti con la mediana della rispettiva colonna. Questa scelta consente di mantenere tutte le osservazioni disponibili, evitando che la presenza di valori mancanti comprometta l'addestramento del modello.

Il dataset è stato poi suddiviso in variabili di input e variabile target. La variabile da predire è `WineQuality`, mentre le feature utilizzate per la PCA sono state selezionate escludendo `WineQuality`, `Synthetic_Noise_Flag` (dopo aver selezionato solo i dati privi di rumore come fatto anche nelle pipelines descritte precedentemente) e `Volatile_Enhanced`. In questo modo la trasformazione viene applicata solo alle variabili descrittive continue ritenute utili per la classificazione.

Le feature sono state standardizzate mediante `StandardScaler`. Questa fase è fondamentale per la PCA, poiché il metodo si basa sulla varianza delle variabili: senza standardizzazione, le feature con scala numerica più ampia avrebbero un peso eccessivo nella costruzione delle componenti principali. Lo scaler è stato adattato esclusivamente sul training set tramite `fit_transform`, mentre sul test set è stata applicata la sola trasformazione con `transform`, evitando così fenomeni di data leakage.

Tramite `explained_variance_ratio_` è stata calcolata la quota di varianza descritta da ogni componente, mentre la somma cumulata di tali valori ha permesso di individuare quante componenti fossero necessarie per conservare almeno il 95% della varianza totale.

Il numero ottimale di componenti è stato determinato individuando il primo valore per cui la varianza cumulata risultasse maggiore o uguale a 0.95. Dopo questa scelta, la PCA è stata riapplicata specificando il parametro `n_components`. Il training set e il test set sono stati quindi proiettati nello stesso spazio ridotto, ottenendo rispettivamente `X_train_pca` e `X_test_pca`. Le componenti principali così ottenute sono state poi utilizzate come input per i precedenti modelli di classificazione della qualità del vino.

IV. Risultati sperimentali

In questa sezione vengono analizzate le prestazioni dei modelli implementati, confrontando i risultati ottenuti nelle due diverse configurazioni del dataset (con e senza rumore sintetico).

A. *K-Nearest Neighbors (kNN)*

L'analisi comparativa evidenzia un fenomeno apparentemente

TABLE I
Confronto Performance (Puliti vs. Rumore)

	Dati Puliti			Dati con Rumore			
Classi	**Prec.**	**Rec.**	**F1**	**Prec.**	**Rec.**	**F1**	**Sup.**
3	0.00	0.00	0.00	0.00	0.00	0.00	1
4	0.33	0.10	0.15	0.00	0.00	0.00	10
5	0.43	0.56	0.49	0.50	**0.73**	**0.59**	110
6	0.41	0.40	0.41	0.49	0.45	0.47	102
7	0.22	0.07	0.10	0.50	0.03	0.06	30
8	0.00	0.00	0.00	0.00	0.00	0.00	3
Acc.	—	—	**0.41**	—	—	**0.50**	**256**
Macro	0.23	0.19	**0.19**	0.25	0.20	**0.19**	**256**
Weigh.	0.39	0.41	0.39	0.47	0.50	0.45	**256**

controintuitivo: lo scenario con rumore registra un'accuracy globale superiore (0.50) rispetto allo scenario con soli dati puliti (0.41). Si tratta di una sorta di Paradosso dell'Accuracy, comportamento tipico nei modelli di Machine Learning quando vengono applicati a dataset fortemente sbilanciati. Geometricamente, il rumore distorce le feature disperdendo i pochi campioni delle classi rare (3, 4, 7, 8) e distruggendone i deboli confini decisionali. Di conseguenza, le classi maggioritarie 5 e 6 (212 istanze su 256) saturano lo spazio metrico e per voto di maggioranza, i punti minoritari vengono sistematicamente assegnati a esse. Poiché l'accuracy pesa i singoli campioni e non le categorie, la sovra-predizione delle classi frequenti compensa il fallimento sulle rare, innalzando ingannevolmente la metrica globale. Per valutare la reale capacità predittiva del modello si considera quindi la metrica F1-Macro. che, contrariamente all'accuracy, pesa equamente ogni classe anziché i campioni.

Osservando i risultati, la F1-Macro rimane identica e fissa a 0.19 in entrambi gli scenari, suggerendo che non è l'assenza del rumore a poter migliore le prestazioni dello stesso algoritmo. Inoltre, analizzando le singole classi, emergono tre importanti osservazioni:

- in entrambi gli scenari, le classi estreme 3 e 8 presentano Precision, Recall e F1-Score = 0.00. Ciò evidenzia che il modello soffre della bassa densità di dati, risultando quindi incapace di apprendere dei pattern distintivi.
- Nello scenario con dati puliti, il modello riconosce la classe 4 (F1-Score = 0.15 e Precision 33%) contrariamente allo scenario con rumore in cui le performance crollano a zero.
- Per la classe 7 nello scenario con rumore la Precision sale da 22% al 50% ma a fronte di una Recall che passa da 0.07 a 0.03: anche qui il modello continua a preferire le classi centrali.

B. *Regressione Logistica (RL)*

L'analisi dei risultati ottenuti tramite Regressione Logistica

evidenzia un comportamento fortemente influenzato dallo sbilanciamento della variabile target.

TABLE II
PRESTAZIONI DELLA REGRESSIONE LOGISTICA (DATI PULITI)

Classi	Cross-Validation			Test Set			Sup.
	Prec.	Rec.	F1	Prec.	Rec.	F1	
3	0.00	0.00	0.00	0.00	0.00	0.00	1
4	0.00	0.00	0.00	0.00	0.00	0.00	10
5	0.43	0.60	0.50	0.43	0.62	0.51	110
6	0.40	0.41	0.40	0.49	0.48	0.49	102
7	0.00	0.00	0.00	0.00	0.00	0.00	30
8	0.00	0.00	0.00	0.00	0.00	0.00	3
Acc.	–	–	**0.42**	–	–	**0.46**	**256**
Macro	0.14	0.17	0.15	0.15	0.18	0.17	256
Weigh.	0.34	0.42	0.37	0.38	0.46	0.41	256

Dalla Tabella II emerge che la Regressione Logistica ottiene prestazioni migliori sulle classi maggioritarie, cioè 5 e 6. In particolare, sul test set la classe 5 raggiunge una Recall pari a 0.62 e un F1-Score pari a 0.51, mentre la classe 6 ottiene una Precision pari a 0.49, una Recall pari a 0.48 e un F1-Score pari a 0.49. Questo indica che il modello è in grado di riconoscere parzialmente i vini appartenenti alle categorie centrali di qualità, ma continua a confondere frequentemente le due classi tra loro.
Al contrario, le classi 3, 4, 7 e 8 presentano Precision, Recall e F1-Score pari a 0.00 sia in cross-validation sia sul test set. Questo risultato mostra che il modello non riesce ad apprendere pattern sufficientemente distintivi per le classi meno rappresentate.
Di conseguenza, l'accuracy risulta una metrica parzialmente ingannevole in questo contesto. Poiché il dataset è fortemente sbilanciato, un modello che predice prevalentemente le classi 5 e 6 può ottenere un'accuracy discreta senza essere realmente efficace sulle classi rare. Per questo motivo, l'F1-Macro rappresenta anche in questo caso una misura più significativa della qualità complessiva del classificatore, poiché assegna lo stesso peso a ogni classe indipendentemente dal numero di campioni.

C. *Random Forest (RF)*

L'algoritmo Random Forest evidenzia prestazioni significativamente superiori rispetto ai modelli precedentemente analizzati, mostrando una maggiore capacità di generalizzazione anche in presenza di un forte sbilanciamento della variabile target e raggiungendo un'Accuracy pari a 0.88 e un F1-Macro anch'esso pari a 0.88.
A differenza di kNN e della Regressione Logistica, il modello riesce infatti a riconoscere efficacemente anche le classi minoritarie, ottenendo valori elevati di Precision, Recall e F1-Score su quasi tutte le categorie qualitative.

TABLE III
PRESTAZIONI DEL MODELLO RANDOM FOREST (DATI PULITI)

Classi	Prec.	Rec.	F1	Sup.
3	1.00	1.00	1.00	438
4	0.99	1.00	0.99	438
5	0.67	0.72	0.69	438
6	0.73	0.63	0.68	438
7	0.91	0.93	0.92	438
8	0.98	1.00	0.99	438
Acc.	–	–	0.88	2628
Macro	0.88	0.88	0.88	2628
Weigh.	0.88	0.88	0.88	2628

Le classi estreme 3 e 8 assumono valori quasi perfetti di Precision, Recall e F1-Score, evidenziando come il modello sia in grado di appredere pattern distintivi anche per categorie caratterizzate da un numero limitato di osservazioni nel dataset originale.
Tale comportamento è favorito dall'applicazione della procedura di oversamplimng, che consente di bilanciare artificialmente la distribuzione delle classi durante la fase di addestramento.
Le principali difficoltà residue si osservano tra le classi centrali 5 e 6, che presentano frequenti sovrapposizioni nelle predizioni del modello. Questo comportamento suggerisce che vini appartenenti a tali categorie condividano caratteristiche chimico-fisiche molto simili, rendendo più complessa la distinzione tra le due classi anche per un modello robusto come il Random Forest.

D. *Principal Component Analysis (PCA)*

L'applicazione della PCA non ha portato a un miglioramento delle prestazioni rispetto ai modelli addestrati senza riduzione della dimensionalità. Al contrario, la trasformazione delle variabili originali in componenti principali sembra aver causato una perdita di informazione utile per la classificazione della qualità del vino.
Tra i modelli testati, la Random Forest ha ottenuto l'accuratezza migliore, pari a `0.4297`. Il modello riesce a riconoscere parzialmente solo le classi più rappresentate, in particolare le qualità 5 e 6, mentre non riesce a classificare correttamente le classi meno frequenti.
Il modello K-Nearest Neighbors ha raggiunto un'accuratezza pari a `0.4062`, mostrando un comportamento simile alla Random Forest ma leggermente peggiore. Ciò suggerisce che la riduzione della dimensionalità non è stata sufficiente a rendere le distanze tra i campioni realmente più informative.
Infine, la Regressione Logistica ha ottenuto il risultato peggiore, con un'accuratezza pari a `0.1797`. A differenza della versione precedente, il modello lineare non riesce a separare correttamente le classi nello spazio delle componenti principali. I valori bassi di precision, recall e `f1-score` mostrano che la PCA, in questo caso, ha peggiorato la capacità discriminante del modello.

V. CONCLUSIONI

L'analisi sperimentale ha evidenziato differenze significative tra i modelli considerati per la classificazione della qualità del vino rosso. I risultati ottenuti mostrano come kNN e Regressione Logistica siano in grado di riconoscere principalmente le classi centrali maggiormente rappresentate nel dataset, incontrando invece difficoltà nella classificazione delle categorie minoritarie. L'applicazione della PCA non ha inoltre prodotto miglioramenti apprezzabili delle prestazioni, suggerendo una perdita di informazioni discriminanti dovuta alla riduzione della dimensionalità.
Tra gli algoritmi analizzati, Random Forest si è dimostrato il metodo più efficace, grazie alla sua capacità di gestire relazioni non lineari tra le variabili e di riconoscere correttamente sia le classi maggioritarie sia quelle meno rappresentate. L'utilizzo dell'oversampling ha inoltre contribuito a migliorare il riconoscimento delle classi meno rappresentate, rendendo il modello più robusto rispetto agli altri approcci considerati.
Dal punto di vista applicativo, i risultati ottenuti mostrano come sia possibile sfruttare i dati chimico-fisici raccolti durante il processo produttivo per costruire sistemi di supporto alle decisioni capaci di stimare automaticamente la qualità del vino. L'adozione di un sistema automatico basato su Random Forest consentirebbe di ridurre i costi legati alle degustazioni di esperti, migliorare la coerenza delle valutazioni eliminando la soggettività umana e supportare tempestivamente le decisioni produttive, come interventi correttivi in cantina o la selezione dei lotti per diverse fasce di prezzo. Tali strumenti possono rappresentare un valido supporto ai processi di controllo qualità e alle decisioni aziendali nel settore vitivinicolo.